

单字方案的码长-重码权衡还有很大的提升空间

给定一种汉字编码输入方案，它能否同时实现低码长和低重码呢？这是汉字编码输入方案中的核心问题之一。很明显，我们不能无限地同时降低码长和重码，在数学上二者需要受到 Kraft-McMillan 不等式的限制。不妨设单个消息（标点、字、词或句）的码长为 $1 \sim 4$ 不等，且码长为 $1 \sim 4$ 的消息数量分别为 l_1, l_2, l_3, l_4 ，方案使用键的个数为 r ，则必须满足

$$l_1 r^{-1} + l_2 r^{-2} + l_3 r^{-3} + l_4 r^{-4} \leq 1$$

这就是对于方案设计的约束。在这种约束下，我们要同时优化码长和重码，其特点为：

- 重码的估计值：根据[重码估计方法](#)，给定 N 个消息，若假定随机编码到 $M = l_1 + l_2 + l_3 + l_4$ 个空间内，产生的选重数约为 $N^2/2M$ ；
- 码长的估计值：假定编码所采用的简码设置策略极其有效，可以保证高频的消息总是被分配到较短的编码，则前 l_1 个消息被分配为 1 码、 $l_1 + 1 \sim l_1 + l_2$ 个消息被分配为 2 码、.....，则码长将取决于频率分布和 l_i 的具体大小。

这个问题的精确求解是比较困难的，并且涉及到不同的人对于码长和重码的不同权重，难以给出一个决定性的解。但是，我们可以用绘图的方式，在二维空间中描绘出不同的方案对应的码长和重码估计值，从而可视化地大致判断哪些方案更接近 Pareto 前沿。

单字输入方案

我们首先考虑单字输入方案，因为针对单字研究的顶功格式比较丰富。


有简打简的情况

我们采取以下这些大家所熟悉的顶功和前缀码的模型，公平起见它们都使用 30 个键和空格，并在计算码长时考虑标点：

- Huffman 编码：无理前缀码，理论上效率最优；
- 一码顶：采用 18 键大集合、12 键小集合；
- 二码顶：采用 18 键大集合、10 键小集合、2 键保留给逗号句号；
- 一二码混顶：采用 18 键大集合、6 键小集合、6 键保留给逗号句号和其他一码字；
- 四二顶：采用 28 键编码，二码可顶、三码加空格
- 三码定长：采用 28 键
- 四码定长：采用 28 键
- 非定长前缀码：采用 20 键大集合、10 键小集合

并将除 Huffman 编码外每个方案中二码及以上的编码都视为可以用于全码的编码空间，以此来估计静态重码率 $N/2M$ ，其中待编码字数设为 $N = 6000$ 。得到结果后，在码长线性、选重率对数坐标轴上绘制散点图：

理想单字输入方案的码长-重码分布图




按照码长从低到高的顺序，对上图解读如下：

- Huffman 编码的码长为 2.02
- 使用一二码混顶可以轻易接近这个极限（2.04），但它的重码率则很高
- 若增大小集合的数量，采用 18+12 的一码顶和 18+10+2 的二码顶可以在损失约 0.1 的码长的情况下明显改善重码率
- 四二顶虽然码长不如二码顶、空间也更小，但是胜在规则简单、简码级数少，和理论极限的差距可以在 0.2 以内；
- 采用 20+10、类似于卿云规则（双编码，Aa ABb ABCc ABCD）的前缀码和理论极限的差距在 0.3 以内，但它的空间很大，和四码定长只有 1 倍的差距，因此研究潜力巨大；
- 三码定长的性价比则较低，因为在有简打简的情况下四码定长有大量的二简也是三键打出，在少了几十倍编码空间的情况下只能降低约 0.1 码长

只使用一简的情况

假定方案只使用全码和一级简码，全码的码长与「卿云输入法」中相同，则可以绘制出如下的散点图：

理想单字输入方案的码长-重码分布图（全码 + 一简）



这里四定的码长来到了 3.22，和三定的差距来到了 0.6，因此全码单字派采取三码定长仍然是有一定吸引力的。尽管如此，前缀码在最长 4 码的情况下仍然能以 0.1 的码长劣势换来相对于三码定长 10 倍的编码空间提升，因此仍然显得性价比比较高。

数值求解 Pareto 前沿及其启示

我们现在尝试跳出既定的顶功或前缀码的思维框架，直接去求解由 Kraft-McMillan 不等式和两个目标函数给出的优化问题对应的 Pareto 前沿到底是什么，这样可以不落窠臼，充分揭示目前顶功或前缀码的局限性。


定义实值函数 $f: \mathbb{N} \rightarrow \mathbb{R}$ 来表示前 x 个消息对应的累积总频率，则满足 $f(0) = 0, f(N) = 1$ ，中间变化过程是非线性的。码长可以表示为

$$\begin{aligned} L &= f(l_1) \times 1 + [f(l_1 + l_2) - f(l_1)] \times 2 \\ &\quad + [f(l_1 + l_2 + l_3) - f(l_1 + l_2)] \times 3 + [1 - f(l_1 + l_2 + l_3)] \times 4 \\ &= 4 - f(l_1 + l_2 + l_3) - f(l_1 + l_2) - f(l_1) \end{aligned}$$

选重率 $S = N^2/2(l_1 + l_2 + l_3 + l_4)$ 。 L 和 S 就是两个简单的非线性目标函数。方便起见，我们让 Kraft-McMillan 总是取等号，做如下代换

$$l_4 = r^4 - r^3 l_1 - r^2 l_2 - r l_3$$

然后让 l_1, l_2, l_3 分别在网格上枚举（例如 $l_1 = 0 \sim 29, l_2 = 0 \sim 899, \dots$ ），排除掉不符合约束的值，然后计算 L, S 。



可见，在格式层面还有很大的提升空间。