

在传统的中文编码输入方案设计中，无论使用什么编码方式（音码、形码等等），其编码效率（即码长）都要受到信息熵的限制。例如，如果测定汉字的信息熵是 6 bit/字，而使用 26 键输入，则码长不可能低于 $6/\log_2(26) = 1.3$ 。生成式 AI 出现之后，根据信息论估计的码长极限已经失效了，因为码长理论上可以是 0，即直接让 AI 在上下文中生成所有内容。当然，这样无法保证生成的内容是用户当前要输入的（例如聊天、笔记或写作的相关内容），但一定存在一个「增加一点码长 → 就能更符合一点用户意图」的连续统，可以渐进地提升符合用户意图的程度，而且这个程度不需要达到 100%，因为语言必定存在一些润色的自由度。因此，在当前趋势下，只有重新设计一种 AI 原生的编码和交互方式，才能让编码输入的效率有本质提升。

这是我刚想到的一个想法，请你评价这个想法。现在假设我们的编码仍然以汉语拼音为基准，我们先试图抛开传统的输入方式（例如全拼、双拼、简拼以及冰雪四拼等方式）。那么重新设计的这种 AI 原生的编码和交互应该是什么样子的？请给出几个研究方向。

你的这个想法抓住了一个非常本质的变化：从“编码传输信息”转向“引导生成模型收敛到意图”。从信息论角度看，传统输入法是在一个无上下文或弱上下文信道里编码字符，而 LLM 引入的是一个强先验（context prior）+ 条件生成信道，这确实让经典的「每字固定信息熵 → 最短码长」模型不再适用。

不过有一点需要稍微“纠偏”：

码长极限并没有失效，而是从“字符熵 $H(\text{字})$ ”转变为“在上下文条件下的条件熵 $H(\text{字} | \text{上下文})$ ”。

LLM 做的事情，本质上是在极大地压低这个条件熵——甚至在很多位置接近 0。因此你说“码长趋近于 0”在工程上可以理解为：用户不再编码字符，而是在减少不确定性。

下面我从系统设计角度，把你这个思路拆成几个可以做研究的方向（尽量贴近你做输入法的背景）。

一、从“编码字符”到“编码意图”：重新定义输入目标

传统输入法：

用户 → 编码 → 字符序列

AI 原生输入法：

用户 → 约束/提示 → 模型 → 候选文本 → 用户修正

关键变化：

- 输入不再是“确定性映射”
- 而是“逐步收缩候选空间”

👉 可以把整个过程形式化为：

每一次按键 = 对 posterior 分布的一次“信息增益操作”

二、研究方向 1：“最小干预输入”（Minimum Intervention Input）

核心问题：

用户最少需要提供多少信息，模型就能收敛到正确文本？

这可以变成一个非常漂亮的理论+工程问题：

1.1 信息论版本

目标：

$$\min \text{User Bits} \quad s.t. \quad P(\text{目标文本} \mid \text{输入}) > \tau$$

这里 τ 可以是：

- Top-1 命中
- 或 Top-k 覆盖

👉 这直接对应你说的“渐进逼近意图”。

1.2 交互策略设计

你可以研究：

- 哪种输入最“省信息”？
 - 拼音片段？
 - 关键词？
 - 语义标签？
 - 编辑操作（删除/替换）？
- 是否可以：
 - 自动选择“最有信息量”的提示？
 - 类似 active learning / query selection

👉 这会变成一个人机协同编码问题

三、研究方向 2：“连续编码” vs “离散编码”

传统输入：

- 离散：键盘 → 字母 → 字

AI 输入可以是：

2.1 连续信号

- 按键节奏 (timing)
- 输入停顿 (hesitation)
- cursor movement

这些都可以作为隐式信号：

“我不太确定这里”

“这个词很重要”

👉 本质是把输入信号从 **symbolic** → **analog**

2.2 低码长语义触发器

例如：

- zg jj → 自动展开为“中国经济形势分析...”
- 甚至：
 - 一个字母触发一个模板分布

这类似：

- prompt compression
- 或 latent code

👉 可以研究：

“拼音是否可以成为 latent semantic key? ”

四、研究方向 3：基于拼音的“概率路径输入”

你提出“仍以拼音为基准”这一点非常关键。

但拼音不必再是“确定编码”，可以变成：

3.1 模糊路径 (probabilistic path)

用户输入：

zh g j



系统维护：

- 所有可能解释路径
- 并用语言模型排序

👉 和传统输入法不同：

- 不再 resolve 到“字”
 - 而是 resolve 到“句子分布”
-

3.2 prefix as constraint, 而不是 mapping

拼音的作用变成：

限制 token space, 而不是决定 token

例如：

- bei → 不只是“北/被/备”
 - 而是所有符合语境的 continuation
-

五、研究方向 4：交互式重写（Interactive Rewriting）

这是最有潜力替代输入法的方向之一：

4.1 用户不“输入”，而是“编辑生成结果”

流程：

1. AI 生成一整句
2. 用户：
 - 删除一部分
 - 改一个词
 - 输入几个拼音
3. 模型重新生成

👉 类似：

- diffusion + inpainting
 - program synthesis + refinement
-

4.2 局部约束

用户输入拼音：

... 我觉得这件事情很 [zhongyao]



系统：

- 只在该位置做 constrained decoding

👉 可以研究：

- 局部条件生成
 - alignment with cursor position
-

六、研究方向 5：用户意图建模（User Intent Model）

你提到一个非常关键的问题：

AI 生成的内容未必是“用户想输入的”

这本质是：

$$P(\text{text} \mid \text{context}) \neq P(\text{text} \mid \text{user intent})$$

所以需要：

5.1 用户特化模型

- 写作风格
 - 常用表达
 - 当前任务（聊天 / 论文 / 笔记）
-

5.2 即时意图状态（session-level latent state）

可以建模为：

- 一个 latent vector z
- 用户输入不断更新 z

👉 这非常像：

- online Bayesian inference
-

七、研究方向 6：“码长—认知负担”权衡

一个很容易被忽略但很重要的点：

👉 码长减少 $\neq$ 输入效率提升

因为：

- 用户需要验证 AI 输出
- 需要修正错误

所以目标函数应该是：

$$\text{Total Cost} = \text{Typing Cost} + \text{Verification Cost} + \text{Correction Cost}$$

这会带来一个关键 insight:

👉 最优系统不是“零输入”
而是“最小总认知负担”

八、几个具体可落地的系统原型

给你一些更具体、可以做 demo / paper 的方向:

8.1 “半句生成输入法”

- 用户输入前几个拼音
- 系统生成整句
- 用户继续修正

类似:

- Copilot for Chinese typing
-

8.2 “关键词驱动输入”

用户输入:

北京 天气 周末



系统生成:

这个周末北京天气预计...

8.3 “拼音 + 编辑操作混合语言”

用户操作变成一种 DSL:

+zhongyao # 插入“重要”
-del # 删除上一词
/rew # 重写句子



👉 这是一个输入语言设计问题

8.4 “候选不是词，而是句子”

传统:

- 候选：字 / 词

AI:

- 候选：整句 / 段落

👉 可以研究:

- 候选排序
- 多样性 vs 精确性

九、一个更激进的观点（供你参考）

你这个方向如果走到底，结论可能是：

“输入法”这个概念本身会消失
被“意图编辑器（intent editor）”取代

而拼音只是：

- 一种低带宽控制信号
- 类似 joystick，而不是键盘

总结

你的核心洞察可以提炼为一句话：

未来输入的本质不是“编码文本”，而是“减少模型的不确定性”。

可以重点考虑三个最有研究价值的方向：

1. 最小干预输入（信息论 + HCI）
2. 拼音作为概率约束（而非确定编码）
3. 交互式生成 + 局部重写机制

如果你愿意，我们可以下一步把其中一个方向（比如“拼音概率路径输入”）具体化成一个**系统架构 + latency 预算 + API 设计**，这会更贴近你一开始提到的实时性问题。

📄 🌟 💬 ↗️ ↺ ...