

N元汉字字词编码输入的最短码长和速度上限^②

王晓龙

王 轩

(哈尔滨工业大学计算机系)

【摘要】本文介绍了计算 N 元字词编码最短码长的方法, 给出了理论证明和实现算法, 并在 IBMPC 和工作站上就 52 万字和 180 万字的样本数据对 N 取 24 种不同的码元情况下进行了计算, 给出了各种常见的输入方案的码长下限。基于上述计算结果, 本文还就最短码长精度、码元 N 与编码效率、词数与码长的关系以及录入员平均输入速度的上限进行了讨论。

一、问题的提出

汉字编码输入是中文信息处理领域里非常活跃的一个分支。从 1978 年以来, 已经经历了单字编码输入, 词组输入, 语句输入三个发展阶段[1]。易学性不断改进, 用户界面更加友好, 平均击键数逐步减少, 面向专业操作员和非专业操作员的汉字输入速度不断提高, 决定汉字系统总体性能的各个方面都有很大的进展。但是, 由于不同用户具有不同的评价标准, 只强调某一方面尤其是输入速度或平均码长的宣传对汉字输入研究的方向以及社会的导向仍有着不可忽视的作用, 以至于存在着输入速度超过 300 字/每分钟甚至一键一字输入系统的报导。因此, 研究汉字编码输入的最短码长, 进而推导出汉字输入速度的上限, 对汉字输入系统的评价以及确定汉字输入技术的研究方向具有重要的意义, 还有助于打破某些关于汉字输入的神话, 澄清汉字输入的现实。

二、 N 元字词编码的平均码长

设样本 SAM 中的汉字总数为 C , 其中不同汉字的字种数为 n , 每个汉字在样本 SAM 中的出现次数为 $c(i), (i=1, \dots, n)$, 汉字编码的码长为 $l(i)$, 汉字的频度为 $p(i), p(i) = c(i)/C$, 则有:

①本文1993年1月20日收到

②本研究得到国家自然科学基金、国家教委博士点基金和霍英东基金的资助。

$$C = \sum_{i=1}^n c(i)$$

设样本 SAM 中的汉字总数为 W ，其中不同的词数为 m ，每个词在样本中出现的次数为 $w(j), j = (1, \dots, m)$ ，词长（所含汉字的个数）为 $t(j)$ ，汉字编码的码长为 $L(j)$ ，词的频度 $P(j) = w(j) / W$ ，则有：

$$W = \sum_{j=1}^m w(j)$$

字词之间的关系为：

$$C = \sum_{i=1}^n c(i) = \sum_{j=1}^m w(j)t(j)$$

令汉字编码的码元数（即使用的键数）为 N ，对于单字编码输入，样本 SAM 中 C 个汉字所需击键数为：

$$\sum_{i=1}^n c(i)l(i)$$

单字输入的平均码长为：

$$\sum_{i=1}^n (c(i) / C) l(i) = \sum_{i=1}^n p(i) l(i)$$

对于词组编码输入， C 个汉字的样本 SAM 所需击键数为：

$$\sum_{j=1}^m w(j)L(j)$$

词组输入中汉字的平均码长为：

$$(1 / C) * \sum_{j=1}^m w(j)L(j) \quad (1)$$

词组输入中单词的平均码长为：

$$\sum_{j=1}^m (w(j) / w) L(j) = \sum_{j=1}^m P(j) L(j)$$

如果直接按单字计算，每个词码输入的单字次数应为 $w(j)t(j)$ ，所对应的单字码长应为 $L(j) / t(j)$ ，则汉字的平均码长应该为：

$$(1/C) \sum_{j=1}^n w(j) t(j) \frac{L(j)}{t(j)}$$

同样可以得出(1)式。

三、最短码长的求解

最短码长的标准是使得下面的码的长度的数学期望取最小值。

$$\sum_{i=1}^n p(i) L(i)$$

其中: $L(i)$ 是第 i 个字(词)的码的长度, 而 $p(i)$ 是第 i 个字(词)出现的几率。

文献[2]给出了二元编码最短码长的求法, 按照其思想, 可以推出 N 元编码的最短码长的求法。

设码元数为 N , 一组编码对应着一棵 N 元树, 它的叶子 $v(i)$ 分别对应一权 $p(i)$, $v(i)$ 到树根的长度 (每条边的长度设为 1) 为 $L(i)$ ($i=1, 2, \dots, k$), 求解 N 元最短码长的问题归结为找一颗 N 元树, 使得权

$$M(T) = \sum_{i=1}^k p(i) L(i)$$

取最小值。这样的 N 元树称为最优 N 元树。

不妨设定: $p(1) < p(2) < \dots < p(k)$

定理一: 若 T 是带权 $p(1), p(2), \dots, p(k)$ 的最优 N 元树的集合, 则 T 中必含有一棵最优 N 元树 T_1 , 使 T_1 中, $p(1), p(2), \dots, p(t)$ 为兄弟, 这里:

$$t = \begin{cases} N-1 & r=0 \\ N & r=1, r = MOD(k, N-1), \text{即 } k/(N-1) \text{ 的余数.} \\ r & 1 < r \end{cases}$$

证明: (1) $p(1)$ 一定有兄弟, 因为 $p(1)$ 最小, 故对应长度 $L(1)$ 应该最长, 若没有兄弟如图 1 所示, 则立即可以得到一个权更小的树, 这只要令它的父亲带权 $p(1)$, 即可。

(2) 存在一棵最优 N 元树, 除了 $p(1), \dots, p(t)$ 兄弟结点外, 其它部分为一棵完全 N 元树[3], 因为只要有一个结点的分支少于 N , 这可以令 $p(1)$ 补上, 形成一个权值更小或相等的新树, 这和已知矛盾。

(3) 用数学归纳法可以证明: 一个完全 N 元树叶子结点的个数 $X = (N-1) * C + 1$, C 为正整数。将 $p(1), \dots, p(t)$ 兄弟结点和完全 N 元树合在一起, 并考虑到其父结点占用 N 元

树的一个叶子结点, 则由 (2) 导出: 存在一棵最优 N 元树 T_1 , 其叶子结点个数 $K = t + X - 1$, 且 $p(1), \dots, p(t)$ 为兄弟。因此:

$$t = K + 1 - X = K - (N - 1) * C$$

等式两边对 $N-1$ 取模,

$$\text{MOD}(t, N-1) = \text{MOD}(K - (N-1) * C, N-1) = \text{MOD}(K, N-1)$$

由(1)知, $P(1)$ 一定有兄弟, 因此, t 的取值范围为 $2 \leq t \leq N$, 而根据取模定义, 对任意正整数 Y , $0 \leq \text{MOD}(Y, N-1) \leq N-2$, 可以推出: 当 $2 \leq \text{MOD}(t, N-1)$ 时, $t = \text{MOD}(t, N-1)$, 当 $\text{MOD}(t, N-1) = 0$ 或 1 时, $t = \text{MOD}(t, N-1) + N - 1$, 定理一得证。




图 1




图 2

设 T_1 是定理 1 所述的一棵最优 N 元树, T_2 是用 $p(1), p(2), \dots, p(t)$ 的父亲结点取代它们作为叶子结点的一棵 N 元树, 其新的叶子结点值为 $p(1) + p(2) + \dots + p(t)$, 如图 2 所示, 显然有:

$$M(T_2) = M(T_1) - p(1) - p(2) - \dots - p(t)$$

又令 T_{21} 是带权 $p(1) + p(2) + \dots + p(t), p(t+1), \dots, p(k)$ 的最优 N 元树, 而 T_{12} 是 T_{21} 中

叶子结点 $p(1)+p(2)+\dots+p(t)$ 生成的 t 个新结点 $p(1), p(2), \dots, p(t)$ 的 N 元树, 如图 3 所示.




图 3

显然: $M(T_{12}) = M(T_{21}) + p(1) + p(2) + \dots + p(t)$

因为 T_{21} 是最优 N 元树, 所以

$$M(T_{21}) < M(T_2)$$

即: $M(T_{12}) - p(1) - p(2) - \dots - p(t) < M(T_1) - p(1) - p(2) - \dots - p(t)$

因为 T_1 是最优 N 元树, 所以 T_{12} 是最优 N 元树.

这就是说, 可以从一带权 $p(1)+p(2)+\dots+p(t), p(t+1), \dots, p(k)$ 的最优 N 元树, 推出一带权 $p(1), p(2), \dots, p(k)$ 的最优 N 元树. 结合定理一多次类推即可得到 N 元最优树, 从而得出最短码长的求解方法:

(一) 树的生成

- 1、把所有元素放在一个集合里,
- 2、据集合中的元素个数 k 和 N 求出 t , 在集合中按频度顺序从小到大取出 t 个元素, 合为一个新的元素放入集合中, 其频度值为 t 个元素的频度值之和, 并记录合并信息.
- 3、反复进行 2, 直到该集合中只有一个元素.

(二) 码长计算

- 1、令树根结点码长为 0
- 2、打开一个合并元素, 根据前面所存的合并信息生成 t 个新的元素, 这 t 个元素的码长+1
- 3、反复进行 2, 直到集合中所有的元素均为树叶结点无法打开为止.
- 4、将所有的叶子结点的码长乘以频度值加在一起即得到最短码长.

例 求带权 0.01、0.02、0.04、0.09、0.1、0.1、0.14、0.5 的最优 3 元树. 求解步骤如图 4 所示, 图中数字①、②、③、④表示步骤:




图4 最优三元树生成举例

$$\text{最短码长} = 3 * (0.01 + 0.02) + 2 * (0.04 + 0.09 + 0.1 + 0.1 + 0.14) + 1 * 0.5 = 1.53$$

四、汉字字词编码输入的最短码长

汉字输入是面向各种领域的，只有在通用领域里求解最短码长才有意义，因此，这就要求样本 SAM 足够大。为此我们分别选用了 52 万字的样本数据[5]和 180 万字的样本数据[6]，实验数据结构如下所示：

词级	词次	词数总计	单字词数	双字词数	三字词数	四字词数	五以上词数
1	72835	1	1	0	0	0	0
2	28881	1	1	0	0	0	0
		...		...		...	
757	1	10364	438	7400	1252	1226	48

在计算机上的机内表示为线性链表，实现算法如下：

- 1、输入词频数据到线性表 A(i)中。
- 2、对 A (i) 中的项按词次由小到大排序。
- 3、计算合并项数 t。
- 4、从线性表 A(i)中取前 t 项形成一个结点，其权值为 t 项频率之和，取出的 t 项都是其结点的儿子。
- 5、判线性表 A(i)是否为空？为空则转 7。
- 6、把新生成的结点插到线性表 A(i)中，转 3。
- 7、从根结点开始，递归访问结点，并赋予每个结点一个编码，即从根结点到该结点

的路径长。

8、根据总字数和总词数计算平均码长。

结点的数据结构为: (value,number,son,next),其中: value 是词次, number 是同词次的词数。该算法用 C 语言实现, 实验结果如表 1 所示, 表中共分 4 栏, N 表示汉字字词编码的码元数, 当 N=5、6、8、26、50、……, 分别对应着五笔划、六笔划、八笔划、26 字母、50 键位等常见的编码法。样本 1 表示 52 万字的实验数据, 样本 2 表示 180 万字的实验数据。栏 2 给出了对应不同码元数时单字编码的最短码长, 栏 3 和栏 4 给出了词组输入时按单字计算的最短码长 (词码的最短码长可以由单字的最短码长乘以平均词长得得出)。栏 2 和栏 3 的结果在 IBMPC386 上运行得出, 栏 4 的结果在工作站 SUN4 上计算得出, 这是由于结点 (即词数) 大量增加, PC 机上的内存已不够用。

五、几点结论

1、表 1 中 N 元编码最短码长的精度

表一、N元字词编码的最短码长

码元N	字输入最短码长(样本2)	词输入最短码长(样本1)	词输入最短码长(样本2)
2	9.249051		
3	5.859267		4.887220
4	4.668234	3.789165	3.882814
5	4.034937	3.275025	3.359293
6	3.637361	2.958052	3.029943
7	3.365215	2.734617	2.803278
8	3.161331	2.565943	2.630263
9	3.003548	2.429419	2.488974
10	2.877180	2.322225	2.376877
16	2.410756	1.954441	2.000732
20		1.819998	1.868184
26	2.081087	1.689009	1.731010
30		1.626607	1.665379
32		1.599322	1.637354
36			1.588847
40			1.546681
50			1.463699
64			1.385051
128			1.218519
256			1.099485
400			1.035908
500			1.007517
1000			0.925618
1500			0.883477

一般认为, 保证一定的精度要求统计样本足够大, 样本字越多, 精度越高。但也不能盲目增加样本字数, 因为精度并非随字数成比例增加, 到了一定的精度, 即使字数增加很多, 所化代价很大, 精度增加也很缓慢。参考文献[7]介绍如果确定汉字的熵要达到精确到两位有效数字 (即一位小数) 的程度, 其可信度达到 99.49%需要选用 50 万字的样本。可以认为, 表 1 中对 52 万字和 180 万字的计算得到的最短码长适用于通常情况的精

度误差在 ± 0.1 以内是基本可信的。

需要指明：最短码长是理论上的极限，是不考虑任何记忆因素和人为因素的情况下得到的，只要是从汉字的形音义等要素推出的具有规则的汉字输入方案，只要是为记忆编码能力远逊于计算机的用户设计的输入方案，其平均码长就不可避免的大于最短码长，规则化越好，易学性越高，例外字越少，则平均码长越大。

例1 文献[8]按照相同语义对应求词熵的假设，给出了最短码长的区间范围，并按照高编码效率0.8的估算，给出了 $N < 40$ 时最短码长为1.25的下限。与表1计算结果相比，该值的估算结果是正确的，但还不够精确。

例2 全息码码长为1.33键的计算方法，没有考虑频度信息，正如文[8]中所述不够科学，不足以作为表1的反例。

例3 文[9]中所述速记汉卡在码元 $N > 42$ （26字母、10数字、5个其它字符和空格）的情况下达到1.51键的情况，尽管采用了频度信息，但由于在计算中将空格作为0.5键计算等情况，也不符合我们的计算要求，因为空格、状态转换符、功能键、重码处理的翻页键、选择键等等所有在汉字输入过程中每一个需要操作的键都应计算在内。

2、码元N和编码效率

从表1中可以看出，当N增大时，最短码长和汉字（词）熵的差距随之增加，编码效率逐步降低。这一点很容易得到解释：当N增大时，处于同一码长的不同频度的差值增加，这和给频度较高的元素赋以较短的码长的思想矛盾。因此，通常把汉字（词）的熵对N取对数计算，从而得出N元编码最短码长的方法还不够精确。

3、词汇数量和码长的关系

汉语词的确认是可变的，对于一固定样本和N，词量的增加未必会使平均码长缩短，这一点从本文中最低码长求解过程中可以得到解释，一般词库都应包含着频度较高的词，当词量到达一定程度后（例如5000常用词的复盖频率已达90%左右），增加的词基本上都是低频词，由于低频词的码长一般大于平均码长，低频词的增加不但不会降低平均码长，反而会使平均码长升高。这一点与文[10]的观点相符。

4、输入速度的上限

在盲打情况下，输入汉字的时间T为[11]：

$$T = \text{编码反映时间} + \text{击键时间}$$

编码反映时间取决于编码方案的易学性和操作者的熟练程度，假设录人员达到熟练程度的极限，编码反映时间为0或和击键时间并行，这时输入汉字的时间由击键时间决定。击键时间与平均码长L和码元N有关，据日本实务用字研究协会发表的日本打字员平均每分钟击键数为：N=26时，为450击，N=50时，为250击，N=2000时，为50击[12]。

对照表1可以很容易给出录人员平均输入速度的上限：

N=26时，为260字/分，N=50时，为171字/分

考虑到录人员长时间持续工作的输入速度和平均输入速度相差不多的情况，该上限也可近似为录人员持续工作的输入速度上限。

需要指出：短时间（例如10分钟）小样本的特殊输入情况不在上述限制之内。

显然，录人员的最高输入速度的上限可以通过把录人员每分钟最高击键数除以最短码

长的简单计算中得到。

参考文献

- [1] 王晓龙: 新一代汉字输入技术的研究和发展, 中国中文信息学会成立十周年学术报告会论文集, 北京, 1991.6
- [2] 卢开澄: 图论及其应用, 清华大学出版社, 1981
- [3] 王遇科, 离散数学结构导论, 国防工业出版社, 1979
- [4] 周炯磐, 信息理论基础, 人民邮电出版社, 1983
- [5] 汉语词汇的统计与分析, 北京语言学院语言教学研究所编, 外语教学与研究出版社, 1985
- [6] 现代汉语频率词典, 北京语言学院出版社, 1986.6
- [7] 赵泊璋, 徐力: 计算机中文处理 (上册), 宇航出版社, 1987, P31
- [8] 李公宣等: 论汉字编码的最短极限码长, 中文信息, 1992.1
- [9] 唐亚伟等: 中文速记汉卡及其编码, 中文信息处理国际会议论文集 (2), 北京, 1992.10
- [10] 张普: 走出汉字键盘输入的三个误区, 中国计算机报, 1992.2.14
- [11] 王晓龙: 汉字输入系统与系列码, 计算机研究与发展, 1985.12
- [12] 陈明远等: 中文编码原理研究, 汉字编码方案汇编, 科学技术文献出版社, 1980

The Limits of Chinese Coding-lengths and input speed

Wang Xiaolong, Wang Xuan

(Dept. of Computer Science, Harbin Institute of Technology)

Abstract

This paper discusses the problem of how to shorten Chinese coding-lengths with N-elements, and proves the best algorithm. The limits of coding-lengths for popular Chinese input schemes are presented based on 0.52 million and 1.8 million characters samples. And then, the precision of the limit of coding-length, the relation of N and coding efficiency, the impact of word number on the code-length and the limit of typist's average input speed is argued.