

在传统的涉及字形的输入方案制作过程中，作者通常需要根据一定的规则手动拆分给定字集中的汉字得到一张「拆分表」。这样做的不便之处是显而易见的：

- 初次拆分需要消耗大量人力；
- 增减字根需要进行大量调整；
- 无法自由改变拆分规则；
- 人工拆分导致了很多人字拆分随意，用户难以快速掌握。

[汉字自动拆分系统](#)实现了一种高效通用的自动拆分方法，大大简化了输入方案的设计。下面我们讲解其实现的原理。

汉字、部件、复合体和字根的关系

观察汉字的字形特点，不难发现汉字分为两类：一类主要由视觉上相连相交的笔画构成，另一类则由几个不相连的块构成；前者的例子如「丁」「七」「万」「丈」……，后者的例子如「汉」「字」「拆」「分」……等等。不仅如此，我们还发现少量的基本结构之间互相组合时，能形成大量的不同汉字，例如「兼」可以分别和不同的偏旁组成「谦」、「嫌」、「兼」、「歉」……

我们将那些比较基本的结构称为「部件」，而由多个部件组成的结构称为「复合体」。这里我们暂且不讨论严格区分他们的标准（关于这一部分请参考[部件与复合体的概念辨析及实践原则讨论](#)），而是先接受「部件」和「复合体」这样一对概念的存在。粗略统计一番，不到一千个部件即可形成几千甚至几万个汉字。

那么汉字编码中用到的「字根」又是怎样的呢？回顾众多方案，我们发现字根一般是以下两种情况之一：

1. 「部件字根」：字根是一个部件。这种情况最常见，例如一些高频的部件「口」「木」「土」「艹」等都常常被选为字根；
 1. 有时候字根是一个部件的一部分，这种情况主要用于比较复杂部件的拆分，例如「尹的前三笔」虽然不是个有构字能力的部件，但是可以用来拆分「尹」「秉」「庚」等字中的部件。像五笔等小字根方案中也有一些类似于「彡」「无撇」这样的小于部件的字根。但统一起见，我们也把这种字根理解为「部件字根」；
2. 「复合体字根」：字根是一个复合体。这通常比较常见于大字根方案，例如「合」「莫」「至」等。

如果字根不是这两种情况之一，那一般称为「怪根」。例如〇九二五笔中有「海去两点」这个字根，它既比部件大，又没完整取完一个复合体。不过由于上面讨论的汉字的组合特性，这种情况总是少数，可以暂且交给人工处理，不强求自动拆分的实现。

因此，一种自然的思路就是，我们首先试图自动地把所有的部件拆分成一个或多个部件字根；然后再沿着汉字组合的顺序逐级考虑越来越复杂的复合体，在这个过程中如果复合体本身就是个字根那就直接使用，否则就用部件的拆分推导复合体的拆分。这个推导的过程要取决于方案的规则（例如有些方案顺序拆分，那把各个部件的拆分连起来就是整个复合体的拆分；有些方案则是分部取码，等等），这里就不展开，下面只考虑各个方案的共性也就是部件拆分的部分，而且默认下面所有的「字根」都是指「部件字根」。

以笔画为最小单位的部件拆分

每个部件含有若干个笔画，通常在视觉上这些笔画是通过相交、相连等关系凝结成一个整体。大多数汉字编码输入方案是以笔画为最小单位来拆分的（去除仓颉、四角号码等特殊情况），意思是当我们把这些笔画不重不漏地分为几组，每组构成一个字根的时候，我们就说这是一个拆分。

为了让接下来的讨论比较简洁，我们这里引入一些形式化的记号。用小写字母 c 表示一个部件（component 的首字母）， s 表示一个笔画（stroke 的首字母），则部件可以记作按一定顺序排列的一组笔画 $c = (s_1, s_2, \dots, s_n)$ 。另外，我们用小写字母 r 表示一个被选为字根的部件（root 的首字母），用大写字母 R 表示所有字根构成的集合。

把部件的这 n 个笔画分为几组，且每组构成一个字根，就完成了拆分。这里每个「组」用 p 表示。例如对于「天」来说，它有 4 笔，其中 $p_1 = (s_1)$ 构成「一」、 $p_2 = (s_1, s_2)$ 构成「二」、 $p_3 = (s_3, s_4)$ 构成「人」、 $p_4 = (s_2, s_3, s_4)$ 构成「大」。我们用小写字母 x 表示按顺序排列的一组字根，例如假设「一」「二」「人」「大」都是字根，那么 $x_1 = (p_1, p_4)$ 是一种可行的拆分， $x_2 = (p_2, p_3)$ 也是一种可行的拆分。

但这里有个问题：怎么自动化地判断「某个部件 c 里的某几笔构成了某个字根 r 」？如果把每个笔画看成是某种矢量图形，那不同的部件中图形会有细微差异，比如「口」和「中」里的「口」高矮胖瘦在具体的矢量图形层面都不一样，但人可以轻易判断「中」里包含「口」字根。这就需要我们引入「退化映射」的概念：

退化映射

退化映射是指将一个部件提取出其中的关键特征，忽略掉图形的具体细节。使用这种方法，如果我们算出某个部件 c 的某几笔经过退化映射之后与某个字根 r 的退化映射相同，那就认为 c 能拆出 r 。例如，「口」和「中」里的「口」高矮胖瘦不一样，但都分别是由「竖、折、横」形成的闭合图形。形式上，退化映射用花体字母记为 $\mathcal{D}$ 。

可行拆分集

有了退化映射之后，我们理论上就可以枚举所有的拆分 x ，构成一个可行拆分集 W ；例如，「三」可以拆分为「一二」、「二一」、「一一一」几种情况；「天」可以拆分为「一大」、「二人」、「一一人」……等若干情况。形式上，可行拆分集的定义为：

$$W = \{x | x \in \pi(c); \forall p \in x, \exists r \in R \text{ s.t. } \mathcal{D}(r) = \mathcal{D}(p)\}$$

上式中 $\pi(c)$ 表示对部件 c 包含的笔画的一种划分方式，例如对于刚才的「天」， $c = (s_1, s_2, s_3, s_4)$ ，那么 $x = ((s_1), (s_2, s_3, s_4))$ 就是一种划分。并且，对于 x 中的每一个组 p ，都存在一个字根 r 使得 r 退化后得到的东西与 p 退化后得到的东西一致。

择优函数

实际的输入方案当然不可能有很多种拆分方式，而是会通过规定「取大优先」「能连不交」等规则来筛选得到最终唯一的拆分。等价地说，我们可以认为存在某个函数，它给每个拆分方式一个「怪异程度」或者说「违和程度」的评价，最后那个最不违和、最容易被人们接受的拆分留了下来。这个函数的具体形式可参见[汉字自动拆分之择优函数](#)，我们这里只需要理解即可。

那个被最终唯一确定的拆分，我们称之为「最优拆分」。注意，这里「最优」和输入方案的评价指标（如重码等）完全没有关系，只是对拆分规则的一种表述。除了最优拆分之外的称为「非最优拆分」。

形式上，我们记择优函数为 $\mathcal{F}$ ，它给 W 中的每一个拆分指定一个实数，并且这个映射是单射，这样可以保证一定能排序出来。

$$\mathcal{F} : W \rightarrow \mathbb{R}$$

最优拆分是 $\mathcal{F}$ 在 W 上的最小值：

$$x^* = \arg \min_{x \in W} \mathcal{F}(x)$$

字根集、退化映射和择优函数完全决定了拆分结果

给定一个部件 c ，我们首先根据字根集 R 和退化映射 $\mathcal{D}$ 确定可行拆分集 W 。又因为每一个拆分都被择优函数 $\mathcal{F}$ 指定了一个不同的实数，我们总能找到数最小的一个拆分 x^* 。上述讨论保证了拆分是唯一的。

W 依赖于 c 、 R 和 $\mathcal{D}$ ； x^* 除了这些还依赖于 $\mathcal{F}$ 。一般来说， $\mathcal{D}$ 和 $\mathcal{F}$ 是方案规则的一部分，不会频繁变动，所以后文中我们一般只会显式写出对 c 和 R 的依赖，即 $W[c, R]$ 和 $x^*[c, R]$ 。

自动拆分的细节

- [汉字笔画的参数曲线表示](#)