



重码估计方法

问题

设有 n 个待编码对象，构成的集合为 S 。

$$S = \{s_1, \dots, s_n\}$$

现对其编码，允许使用的编码空间为集合 $C = \{c_1, \dots, c_k\}$ ，大小为 k ，估计重码的数量。

独立随机编码近似

假设每个对象的编码是随机且独立的，则在编码每个对象时，某码 c 可能被使用的概率是 $1/k$ 。在对集合 S 中的每个字编码时，相当于重复执行 n 次概率为 $1/k$ 的试验，最终 c 被使用的次数 X 满足 $B(n, 1/k)$ 的二项分布，即

$$\mathbb{P}(X = x) = \binom{n}{x} \left(\frac{1}{k}\right)^x \left(1 - \frac{1}{k}\right)^{n-x}$$

若 $X = 0$ 或 $X = 1$ ，则 c 上不发生重码。若 $X \geq 2$ ，则 c 上发生重码，需要选重的数量为 $X - 1$ 。因此，在这个编码上产生的选重数为 $Y = \max(X - 1, 0)$

$$\begin{aligned}\mathbb{E}(Y) &= \sum_{x=0}^{+\infty} \mathbb{P}(X = x) \max(X - 1, 0) \\ &= \sum_{x=1}^{+\infty} \mathbb{P}(X = x)(X - 1) \\ &= \mathbb{P}(X = 0) + \sum_{x=0}^{+\infty} \mathbb{P}(X = x)(X - 1) \\ &= \mathbb{P}(X = 0) + \mathbb{E}(X - 1) \\ &= \mathbb{P}(X = 0) + n/k - 1\end{aligned}$$

这意味着我们只需要计算 $\mathbb{P}(X = 0)$ 即可。根据二项式展开：

$$\mathbb{P}(X = 0) = \left(1 - \frac{1}{k}\right)^n = 1 - \frac{n}{k} + \frac{n(n-1)}{2k^2} - \frac{n(n-1)(n-2)}{6k^3} + \dots$$

注意到，前两项恰和 $n/k - 1$ 抵消，因此在 $1 \ll n \ll k$ 的情况下我们只需要取第三项即可，若要更精确，可取第四项。

$$\mathbb{E}(Y) \approx \frac{n(n-1)}{2k^2} - \frac{n(n-1)(n-2)}{6k^3} \approx \frac{n^2}{2k^2} \left(1 - \frac{n}{3k}\right)$$

而发生重码的总数是全部编码上产生的选重数之和，因此需要乘以 k ，即 $n^2/2k$ 。

另外，如果统计的标准不是选重数，而是涉及的重码总数，则可以表示为 $Z = X \times \mathbb{I}(X \geq 2)$ 的期望，

$$\mathbb{E}(Z) = \sum_{x=2}^{+\infty} \mathbb{P}(X = x)X = \mathbb{E}(X) - \mathbb{P}(X = 1)$$

$$\mathbb{P}(X = 1) = \frac{n}{k} \left(1 - \frac{1}{k}\right)^{n-1} = \frac{n}{k} \left(1 - \frac{n-1}{k} + \dots\right)$$

因此

$$\mathbb{E}(Z) \approx \frac{n^2}{k^2}$$